자료읽기

탐색/분할

모형

# 당뇨병약 매출 분석

20160131 김지현 2020 11 11

## 자료읽기

- tsibbledata::PBS: 호주 월별 의료보험 약처방 65219x9
  - o a10: ATC2=='A10': Antidiabetic drug(당뇨병약) 매출
  - h02: ATC2=='H02': Corticosteroid drug(부신피질 호르몬제:피부질환, 류마티스 등에 쓰임) 매출

역할	변수
index	Month [1M] 1991.7 ~ 2008.6
key	Concession(Concession, General)
	Type{Co-payments, Safty net}
	ATC1{}
	ATC2{}
obs	Script 월별 처방건수
	Cost 월별 처방비용(매출)

```
a10 <- PBS %>%
filter(ATC2=="A10") %>%
select(Month, Concession, Type, Cost) %>%
summarise(TotalC = sum(Cost)) %>%
mutate(Cost = TotalC/1e6) %>% # Cost의 단위를 백만단위로 변경
select(Month, Cost)
a10
```

```
## # A tsibble: 204 x 2 [1M]
##
       Month Cost
##
       <mth> <dbl>
## 1 1991 7 3.53
## 2 1991 8 3.18
## 3 1991 9 3.25
## 4 1991 10 3.61
## 5 1991 11 3.57
## 6 1991 12 4.31
## 7 1992 1 5.09
## 8 1992 2 2.81
## 9 1992 3 2.99
## 10 1992 4 3.20
## # ... with 194 more rows
```

```
TRN <- filter_index(a10, .~'2000 12')
TST <- filter_index(a10, '2001 1'~.)
```


# 탐색/분할

### 시계열 그림

- 결정척 추세가 있고, 분산이 증가하여 이분산이고, 계절성이 존재하므로 비정상 시계열 로보인다.
- 당뇨병 매출액은 연초에 가장 높으며 강한 계절성을 가지고 있다.

```
a10 %>%
autoplot(Cost) +
ylab("Cost(1e6)" )+
labs(title="monthly Cost of Antidiabetic drug")+
xlab("year month")
```


#### monthly Cost of Antidiabetic drug



- 계절성 시각화 (gg\_series, gg\_subseries)
- 1월에 가장 매출이 높은 계절성을 가지고있다.

```
a10 %>% gg_season(Cost, labels = "left")+
ylab("Cost(1e6)")+
xlab("month")+
ggtitle("Seasonal plot : monthly Cost of Antidiabetic drug")
```

#### Seasonal plot: monthly Cost of Antidiabetic drug



```
a10 %>%


gg_subseries(Cost) +

ylab("Cost(1e6)")+

xlab("month")+


ggtitle("Seasonal plot : monthly Cost of Antidiabetic drug")
```

#### Seasonal plot: monthly Cost of Antidiabetic drug




• acf그림에서 자기상관이 사라지지 않는 비정상 시계열의 특징을 보인다.

gg\_tsdisplay(a10, Cost, plot\_type = 'partial')



autoplot(a10, Cost)+geom\_point() +geom\_smooth(method='Im')

## `geom\_smooth()` using formula 'y  $\sim$  x'



### 모형

### 모형 적합

- 시계열 회귀(결정적 추세모형)을 적합
- 시계열 회귀(결정적 추세 + 계절가변수)을 적합

## Warning in report.mdl\_df(MM): Model reporting is only supported for individual ## models, so a glance will be shown. To see the report for a specific model, use ## `select()` and `filter()` to identify a single model.

```
## # A tibble: 2 x 15
##
    .model r_squared adj_r_squared sigma2 statistic p_value
                                                           df log_lik AIC
   <chr>
              <dbl>>
                       <dbl> <dbl>
                                       <dbl> <dbl>
                                           522. 5.57e-44
## 1 LLT
              0.823
                          0.822 0.0235
                                                                53.0 -424.
                          0.978 0.00296 411. 6.31e-80
## 2 LLTS
              0.980
                                                         13
                                                              177. -649.
## # ... with 6 more variables: AICc <dbl>, BIC <dbl>, CV <dbl>, deviance <dbl>,
## # df.residual <int>, rank <int>
```

### TRN에서 모형적합도 비교

- \* TRN에서 MAPE 기준 LLTS=4.01 < LLT=11.3
- \* ALCc 기준 LLTS = -645.2379 < LLT = -423.3805
- \* TRN에서의 성능은 MAPE가 낮은 LLTS가 좋다.

#### accuracy(MM)

#### glance(MM)

```
glance(MM)$AlCc
```


```
## [1] -423.3805 -645.2379
```

#### 적합값 저장/잔차분석


• LLT의 잔차가 패턴을 가지는 것으로 보아 잔차안에 정보가 남아있는 것으로 보인다.

```
AA <- augment(MM)

# LLT (결정적 추세모형) 잔차 잔차분석
gg_tsdisplay(filter(AA, .model=='LLT'), .resid, plot_type = 'partial')+ggtitle('L
LT')
```



# LLTS (결정적 추세 + 계절가변수) 잔차분석 gg\_tsdisplay(filter(AA, .model=='LLTS'), .resid, plot\_type = 'partial')+ggtitle( 'LLTS')



- \* 1만 간격으로 잔차가 등분산인 것으로 보인다.
- \* 잔차안에 정보가 남아있는지 개별모형검토 과정에서 검정으로 확인해봐야한다.
  - 예측값 저장

```
FF <- forecast(MM, new_data = TST)
```

#### TST에서 모형 적합도 비교


- \* TRN에서 MAPE 기준 LLTS=1.82 < LLT=2.97
- \* TST에서의 성능도 LLTS가 더 좋다.

accuracy(FF, data=a10)

```
## # A tibble: 2 x 9
## .model .type ME RMSE MAE MPE MAPE MASE ACF1
## <chr> <chr> <chr> <dbl> = 1.29 1.94 1.47 -7.93 9.07 1.82 0.0742
```

### 예측값 시각화/개별모형 검토

autoplot(FF, data=a10, level=NULL)



```
# 개별모형 검토
# LLT 의 과거값, 적합값, 예측값 시각화
MLLT <- select(MM, LLT)
report(MLLT)
```

```
## Series: Cost
## Model: TSLM
## Transformation: log(.x)
##
## Residuals:
##
       Min
                1Q Median
                                  3Q
                                          Max
## -0.28396 -0.09219 -0.01827 0.06107 0.44589
##
## Coefficients:
##
              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1.2262664 0.0289058 42.42 <2e-16 ***
            0.0099712 0.0004363 22.85 <2e-16 ***
## trend()
## ---
## Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '. 0.1 ' 1
## Residual standard error: 0.1533 on 112 degrees of freedom
## Multiple R-squared: 0.8234, Adjusted R-squared: 0.8218
## F-statistic: 522.3 on 1 and 112 DF, p-value: < 2.22e-16
```

•  $p-value=0.000000822<\alpha=0.05$ 이므로  $H_0:\rho_1=\ldots=\rho_10=0$ 을 기각, 자기상관이 남아있는 것으로 보인다.

```
#gg_tsresiduals(LLT) : 위의 결과와 동일
features(filter(AA, .model=='LLT'),.resid,ljung_box, lag=10, dof=2)
```

```
G1 <- autoplot(filter(FF, .model=='LLT'), data=a10)+ geom_line(aes(y=.fitted, col
  or='Fitted'),data=filter(AA, .model=='LLT'))+ggtitle('LLT')
```

```
# LLTS 의 과거값, 적합값, 예측값 시각화
MLLTS <- select(MM, LLTS)
report(MLLTS)
```


```
## Series: Cost
## Model: TSLM
## Transformation: log(.x)
##
## Residuals:
##
        Min
                   1Q
                         Median
                                      3Q
                                               Max
## -0.127908 -0.031538 0.003248 0.029985 0.192196
##
## Coefficients:
##
                   Estimate Std. Error t value Pr(>|t|)
## (Intercept)
                1.5157854 0.0200487 75.605 < 2e-16 ***
                 0.0099583 0.0001551 64.198 < 2e-16 ***
## trend()
## season()year2 -0.5188019 0.0256583 -20.220 < 2e-16 ***
## season()year3 -0.4145494 0.0256598 -16.156 < 2e-16 ***
## season()year4 -0.4230607 0.0256621 -16.486 < 2e-16 ***
## season()year5 -0.3702870 0.0256654 -14.427 < 2e-16 ***
## season()year6 -0.3627127 0.0256696 -14.130 < 2e-16 ***
## season()year7 -0.2948828 0.0250082 -11.791 < 2e-16 ***
## season()year8 -0.3026255 0.0250087 -12.101 < 2e-16 ***
## season()year9 -0.2974001 0.0250101 -11.891 < 2e-16 ***
## season()year 10 -0.2488409 0.0250125 -9.949 < 2e-16 ***
## season()year11 -0.2324311 0.0250159 -9.291 3.26e-15 ***
## season()year12 -0.0354365 0.0250202 -1.416
                                                  0.16
## ---
## Signif. codes: 0 '*** 0.001 '** 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.05443 on 101 degrees of freedom
## Multiple R-squared: 0.9799, Adjusted R-squared: 0.9775
## F-statistic: 410.9 on 12 and 101 DF, p-value: < 2.22e-16
```

•  $p-value=0.225>\alpha=0.05$ 이므로  $H_0: \rho_1=\ldots=\rho_10=0$ 을 채택, 잔차가 백삭잡음 이고, 모형이 성공적인 것으로 보인다.

```
#gg_tsresiduals(LLTS) : 위의 결과와 동일
features(filter(AA, .model=='LLTS'),.resid,ljung_box, lag=10, dof=3)
```

```
G2 <- autoplot(filter(FF, .model=='LLTS'), data=a10)+ geom_line(aes(y=.fitted, co lor='Fitted'),data=filter(AA, .model=='LLTS'))+ggtitle('LLTS')
```

```
gridExtra::grid.arrange(G1,G2)
```



```
# 예측값 확인
cbind(
  tail(a10)[,c('Month','Cost')],
  LLT = tail(filter(FF,.model=='LLT')$.mean),
  LLTS = tail(filter(FF,.model=='LLTS')$.mean))
```

```
## Month Cost LLT LLTS
## 1 2008 1 29.66536 25.13327 33.09494
## 2 2008 2 21.65429 25.38581 19.89636
## 3 2008 3 18.26495 25.64089 22.30359
## 4 2008 4 23.10768 25.89854 22.33589
## 5 2008 5 22.91251 26.15878 23.78194
## 6 2008 6 19.43174 26.42164 24.20258
```

### 최종모형 - LLTS (결정적 추세 + 계절가변수)

최종모형을 TST에서 MAPE가 낮고, 잔차가 백색잡음인 LLTS(결정적 추세 + 계절가변수)
 로 결정.

```
MLLTS <-model(TRN, LLTS = TSLM(log(Cost)~trend()+season()))
```